

Anonimização de um Dataset com Análise de Risco e Utilidade

Trabalho #3 – Adult Dataset (ARX)

Elementos do grupo: Simão Moreira up202407685, Paulo Pino up202208076 e Rui Pinto up202307701

1. Classificação dos Atributos

Importou-se o adult dataset (32 561 registos, 15 atributos) para o ARX e classificou-se cada atributo como Identifying, Quasi-Identifier (QID), Sensitive ou Insensitive. A classificação assenta em dois critérios: (i) se um adversário consegue obter o valor a partir de uma fonte externa (critério que define um QID) e (ii) os valores de distinction e separation reportados pelo ARX (separador Quasi-Identifiers), que quantificam o poder de discriminação de cada atributo; a tabela reporta a separation como indicador-síntese, tendo ambas as métricas sido inspecionadas no ARX. O adult dataset não contém identificadores diretos (e.g., nome ou número de identificação), pelo que nenhum atributo foi classificado como Identifying.

Atributo	Classif.	Sep. (%)	Justificação
age	QID	97,9	Atributo demográfico observável externamente; elevada separation individual.
workclass	QID	49,7	Tipo de vínculo laboral, observável; reforça a combinação de QIDs.
fnlwgt	Insensitive	~100	Peso amostral do censo; não é externamente associável (não serve para linkage) nem sensível, e tem valor analítico, pelo que se mantém.
education	QID	81,0	Observável; separation forte. Mantido em vez de education-num.
education-num	Removido	—	Codificação ordinal (1–16) do education – mesma informação; removido do dataset (não importado) para não duplicar nem anular a generalização do education.
marital-status	QID	66,0	Estado civil observável; contribui para o linkage.
occupation	QID	90,3	Observável; um dos QIDs mais fortes.
relationship	QID	73,2	Papel no agregado, observável; combina fortemente com occupation (97,0%).
race	QID	26,0	Observável externamente; tratado como QID (ver nota).
sex	QID	44,3	Atributo demográfico observável externamente.
capital-gain	Insensitive	15,9	Maioritariamente 0; separation muito baixa, contribuição desprezável.
capital-loss	Insensitive	9,1	Maioritariamente 0; separation muito baixa.
hours-per-week	QID	76,2	Plausivelmente observável; separation relevante.
native-country	QID	19,7	Observável; baixa separation isolada mas refina o linkage.
income	Sensitive	36,6	Atributo-alvo a proteger de inferência; protegido com distinct I-diversity ($I=2$).

Nota sobre race e occupation. Foram classificados como QIDs por serem observáveis externamente e contribuírem fortemente para a separation (occupation isolada 90,3%; occupation + relationship combinados 97,0%). Sob um modelo de ameaça centrado nas

categorias especiais do RGPD poderiam ser tratados como sensíveis; mantemos income como único atributo sensível para obter uma configuração limpa de I-diversity.

Nota sobre fnlwgt e education-num. O fnlwgt é o peso amostral do censo: não é um QID (não é externamente associável) nem sensível, e tem valor analítico, pelo que se mantém como Insensitive. O education-num é a codificação ordinal (1–16) do education, contendo exatamente a mesma informação; foi removido do dataset (não importado para o ARX) para evitar a duplicação e impedir que o seu valor exato anule a generalização aplicada ao education.

2. Modelos de Codificação (Hierarquias de Generalização)

Para cada um dos 10 QIDs definiu-se uma hierarquia de generalização no ARX. Para os atributos numéricos usaram-se hierarquias baseadas em intervalos; para os categóricos, hierarquias de agrupamento (ordering) com etiquetas atribuídas; os atributos binários/de baixa cardinalidade são generalizados diretamente para *.

- **age (4 níveis):** valor → faixas de 5 anos → faixas de 10 anos → faixas de 20 anos → intervalo total [17,97[.
- **hours-per-week (3 níveis):** valor → bandas de 10 horas → bandas de 20 horas → intervalo total [1,100[.
- **education:** Sem-diploma, Secundário, Vocacional, Superior → *.
- **workclass:** Governo, Self-employed, Privado, Outro → *.
- **marital-status:** Casado, Ex-Casado, Solteiro → *.
- **occupation:** White-Collar, Blue-Collar, Serviços, Outro → *.
- **relationship:** Família, Não-Família → *.
- **native-country:** América-Norte, América-Central/Caraíbas, América-Sul, Europa, Ásia (inclui 'South' = South Korea), Outro → *.
- **sex e race:** generalização direta num único nível → *.

Level-0	Level-1	Level-2	Level-0	Level-1	Level-2
Preschool	Sem-Diploma	*	Adm-clerical	White-Collar	*
1st-4th	Sem-Diploma	*	Exec-managerial	White-Collar	*
5th-6th	Sem-Diploma	*	Prof-specialty	White-Collar	*
7th-8th	Sem-Diploma	*	Sales	White-Collar	*
9th	Sem-Diploma	*	Tech-support	White-Collar	*
10th	Sem-Diploma	*	Craft-repair	Blue-Collar	*
11th	Sem-Diploma	*	Farming-fishing	Blue-Collar	*
12th	Sem-Diploma	*	Handlers-cleaners	Blue-Collar	*
HS-grad	Secundário	*	Machine-op-insp...	Blue-Collar	*
Some-college	Secundário	*	Transport-moving	Blue-Collar	*
Assoc-voc	Vocacional	*	Priv-house-serv	Serviços	*
Assoc-acdm	Vocacional	*	Protective-serv	Serviços	*
Prof-school	Vocacional	*	Other-service	Serviços	*
Bachelors	Superior	*	?	Outro	*
Masters	Superior	*	Armed-Forces	Outro	*
Doctorate	Superior	*			

Figura 1 Exemplo das hierarquias education e occupation.

3. Avaliação de Risco e Utilidade

3.1 Risco de re-identificação do dataset original

Com os 10 QIDs selecionados, o dataset original (não anonimizado) apresenta um risco de re-identificação muito elevado, dominado pelos registos únicos:

Métrica (modelo prosecutor, 10 QIDs)	Valor
Total de registos	32 561

Métrica (modelo prosecutor, 10 QIDs)	Valor
Classes de equivalência	27 515
Registos únicos (classe de tamanho 1)	24 802 (76,17%)
Registos em classes de tamanho ≤ 2	28 272 (86,83%)
Risco prosecutor médio de re-identificação	84,50%
Risco prosecutor máximo	100%
Registos com risco > 20%	30 633 (94,08%)
Registos com risco > 10%	32 015 (98,32%)

O facto de 76% dos indivíduos serem únicos na combinação de QIDs e de o risco prosecutor médio atingir 84,5% confirma que o dataset em bruto não oferece praticamente qualquer proteção contra um ataque de linkage. Esta é a linha de base que os modelos de privacidade abaixo têm de reduzir.




Figura 2 – Distribuição do risco de re-identificação no dataset original (modelo prosecutor): risco médio 84,50%, máximo 100% e 76,17% de registos únicos.

3.2 Modelos de privacidade aplicados

Aplicaram-se dois modelos de privacidade distintos em conjunto e compararam-se os seus efeitos no risco e na utilidade:

- **Modelo 1 – k-anonymity (k = 5) + Distinct l-diversity (l=2) (sobre income):** exige que cada classe de equivalência contenha pelo menos l valores distintos do atributo sensível. Como o income tem apenas 2 valores ($\leq 50K$, $>50K$), o máximo possível é $l=2$ – cada classe terá de conter ambos os valores.
- **Modelo 2 – k-anonymity (k=5) + t-closeness (t=0.2) (sobre income) :** garante que a distribuição do income em cada classe de equivalência não difere em mais de 0.2 da distribuição global do dataset.

A tabela seguinte compara os resultados de ambos os modelos com o dataset original.

Métrica	Original	k=5 + l=2	k = 5 + t = 0.2
Risco prosecutor médio	84,50%	0,098%	0.0307%
Risco prosecutor máximo	100%	1,85%	0.917%
Registos únicos (sample uniques)	76,17%	0%	0%
Population uniques	16,97%	0%	0%
Granularity (utilidade)	—	24,59%	14.93%
Discernibility	—	88,90%	57.757%
Average class size	—	96,88%	90%

Ambos os modelos eliminam completamente os registos únicos (0%) e reduzem o risco prosecutor médio para valores muito baixos (0,098% no Modelo 1, 0,0307% no Modelo 2). O Modelo 2 (t-closeness) apresenta um risco ligeiramente inferior e uma granularidade mais baixa (14,93% vs 24,59%), indicando maior perda de utilidade. Isto é expectável: o t-closeness impõe uma restrição mais forte sobre a distribuição do atributo sensível, forçando generalizações ou supressões adicionais.

Escolha do modelo de privacidade: Apesar de o Modelo 2 oferecer risco marginalmente menor, seleccionou-se o Modelo 1 ($k=5 + l=2$) por apresentar um melhor equilíbrio entre privacidade e utilidade (granularidade 24,59% vs 14,93%) e ser mais do que suficiente para proteger contra ataques de re-identificação e homogeneidade. A configuração de parâmetros deste modelo (nomeadamente o suppression limit) é afinada na secção 3.3, sendo a escolha final apresentada em 3.4.




Figura 3 – À esquerda, dados originais vs. generalizados (Analyze utility); à direita, distribuição de risco antes vs. depois da anonimização (risco médio 0,098%).




Figura 4 – Espaço de soluções (lattice) explorado pelo ARX; o nó da solução ótima aplicada está assinalado.

3.3 Efeito dos parâmetros de configuração

Para analisar o efeito dos parâmetros, variou-se primeiro o valor de k (2, 5, 10, 25, 50) mantendo $l=2$ e suppression limit 0%. Observou-se que a solução ótima é a mesma para todos os valores de k (risco 0,098%, granularity 24,59%): a restrição do distinct l -diversity sobre o income obriga a classes de equivalência suficientemente grandes para satisfazerem simultaneamente todos os k testados, pelo que o k deixa de ser o fator limitante.

Variou-se então o suppression limit (0%, 2%, 5%, 10%), mantendo $k=5$ e $l=2$, parâmetro que produz variação efetiva no compromisso risco/utilidade:

Suppression limit	0%	2%	5%	10%
Risco prosecutor médio	0,098%	0,948%	0,730%	0,438%
Utilidade (Granularity)	24,59%	41,76%	49,32%	52,21%




Figura 5 – Compromisso risco/utilidade em função do suppression limit (k=5, l=2): a utilidade preservada sobe de 24,59% para 52,21% enquanto o risco se mantém sempre abaixo de 1%.

Os resultados mostram um compromisso favorável: aumentar o suppression limit melhora substancialmente a utilidade (a granularidade preservada sobe de 24,59% para 52,21%, mais do dobro), porque ao permitir suprimir alguns registos problemáticos o ARX precisa de menos generalização nos restantes. O risco de re-identificação mantém-se sempre muito baixo (entre 0,1% e 0,95%), uma redução enorme face aos 84,50% do dataset original. É portanto possível ganhar bastante utilidade sem comprometer significativamente a privacidade.

3.4 Iterações e configuração final

Foram realizadas várias iterações: (i) ajuste do valor de l – inicialmente l=3, impossível por o income ter apenas 2 valores distintos, corrigido para l=2; (ii) varrimento do k, que revelou não ser o fator limitante; e (iii) varrimento do suppression limit, que produziu o compromisso risco/utilidade pretendido. A configuração final escolhida é k=5, distinct l-diversity (l=2) sobre income e suppression limit de 10%, por oferecer o melhor equilíbrio: utilidade preservada de 52,21% (mais do dobro da configuração sem supressão) e risco prosecutor médio de apenas 0,438%, mantendo a forte garantia de privacidade.

4. Conclusão

O adult dataset original é altamente re-identificável: 76,17% de registos únicos na combinação dos 10 QIDs e risco prosecutor médio de 84,50%. A aplicação de k-anonymity (k=5) com distinct l-diversity (l=2) reduziu o risco prosecutor médio para 0,098% e eliminou totalmente os registos únicos (0%), à custa de uma utilidade de 24,59%. O varrimento de parâmetros mostrou que, dada a restrição do l-diversity sobre um atributo binário, o k não é o fator limitante, sendo o suppression limit o parâmetro determinante: aumentá-lo até 10% mais do que duplica a utilidade preservada (52,21%) mantendo o risco em apenas 0,438%. A configuração final (k=5, l=2, suppression 10%) oferece assim uma proteção robusta contra a re-identificação com perda de utilidade aceitável.

5. Documentação do Uso de IA

No âmbito da realização deste trabalho, foi utilizado o assistente de inteligência artificial Claude (Anthropic) para apoio na estruturação e revisão do relatório, no esclarecimento de conceitos relacionados com anonimização de dados (k-anonymity, l-diversity, risco de re-identificação e métricas de utilidade) e na orientação sobre a utilização da ferramenta ARX. Toda a classificação de atributos, construção das hierarquias de generalização, configuração dos modelos de privacidade e interpretação dos resultados de risco e utilidade foram realizadas e validadas pelo grupo.